补充材料 年报与法规双源 RAG 的评分量表与检索诊断

本补充材料报告回答质量评分量表、主文引用的候选预算回放与 BM25 定位粒度对照。评分量表在查看输出可用性和部分回答后制定，属于探索性描述评分，并非预注册的 H1/H2 检验。检索诊断复用已保存排序或执行检索，不调用生成模型、不新增答案评分或人工相关性标注；这些结果仅用于说明证据供给与定位边界，不构成回答准确率、检索 Precision/Recall 或法规历史时点适用性验证。法规文献编号沿用主文参考文献。

补充材料 S0 回答质量评分量表

两名评分人员分别按四个维度对每条实际回答给出 0、1、2 或 U。以下判据直接对应原评分包中的评分表，不对已有评分重新赋值。

维度	0 分	1 分	2 分
公司事实	关键公司、数字、成员、日期或报告类型错误，捏造事实；上下文足以回答却完全无理由拒答。	事实总体可靠但主要要点遗漏或表述不够完整；不把输入缺失直接认作公司事项不存在。	准确覆盖本题主要公司要点，区分报告期和期后事项；原金标认定材料不足时，准确说明缺口且不编造亦可得 2 分。
法规依据	关键规范误引或误读，或要求法规依据却仅以公司披露替代且未说明不足。	有相关规范但关键要求遗漏、适用范围或版本限制说明不充分。	主要规范要求准确、有对应原文；适用性可证时正确说明，未知时明确限定；允许经原文核实的其他有效依据。
引用支持	关键引文不存在、与论断相反、张冠李戴或实质内容完全没有依据；只有编号存在不得给分。	部分引文支持但重要陈述缺引用、来源角色遗漏或位置不够精确，未达到整体充分支持。	实质陈述均可由所引原文支持，年报与法规按需引用，来源和页/条可追溯；明确材料不足的合理保留不强迫编造引用。
不确定性处理	把自评当外部鉴证、财报审计当内控专项、拟议当已实施，或无依据认定不存在/合规/违规。	有保留说明但关键边界或限制遗漏；未出现决定性的无据确定判断。	遵守该题最终裁定限制；区分自评/审计、实施/预案、事实/规范，不把未知推成不存在或全面合规。

计分与未知值。 U 表示评分人员无法确定，需说明原因；U 不是 0 分。只有两位人员对四个维度均给出数值时，才计算双方分数总和的一半作为 0–8 分回答得分。失败或未运行的请求不计质量 0 分。该回答评分不等同于治理评分、合规准确率或检索相关性指标。

补充材料 S1 预算配额回放与证据供给

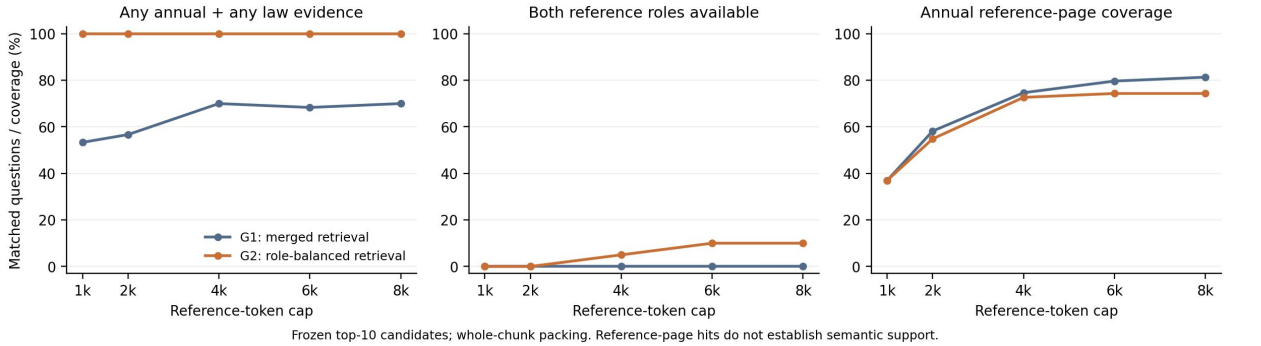
1800 个上下文覆盖五个 token 上限和三个候选配额，使用与历史相同的候选顺序。原配置 120/120 逐字复现，说明后续变化来自本轮指定的候选截取与组装，而不是另一个实现。预算增加允许更多整片段进入，但如果目标原文不在保存候选中，仅增加上下文长度不能恢复它。

在原 6000 配置中，G2 十个候选全部装入，最终法规目标位置仍在 53/60 题缺失；G1 在 60/60 题中都没有严格命中法规参考位置。因此，至少对这些目标来源—页面键而言，主要差距发生在候选选择阶段，而非默认 G2 的 token 组装阶段。若另有等价文本来源获检索，此指标不会计入，需通过独立语义对齐确认。

这项实验不重新搜索候选池之外的片段，也不生成 1800 条答案。它能验证同一保存排序的预算敏感性，不能说明改变 top-k 后重新执行神经检索或重排的端到端效果。高预算回放中的质量推断应停留在证据供给层面；任何回答质量收益仍需要实际生成与独立评分。 预算回放结果见补充表 S1 和补充图 S1。

补充表 S1 预算回放 总候选上限 10

策略	参考上限	保留片段	实际 tokens	双角色出现	角色宏定位覆盖
dual	1000	3.77	953	100.0%	18.5%
dual	2000	6.18	1905	100.0%	27.4%
dual	4000	9.10	3448	100.0%	37.4%
dual	6000	10.00	4032	100.0%	39.1%
dual	8000	10.00	4032	100.0%	39.1%
merged	1000	2.73	868	53.3%	18.5%
merged	2000	4.47	1875	56.7%	29.1%
merged	4000	7.55	3726	70.0%	37.3%
merged	6000	9.37	4945	68.3%	39.8%
merged	8000	10.00	5407	70.0%	40.7%



补充图 S1 新增预算敏感性，总候选上限 10。曲线为缓存候选回放，不包含重检索、生成或新人工评分。

补充材料 S2 BM25 基线与定位粒度敏感性

为避免只对已有结果重画图，本文新增运行同范围的 CPU BM25 检索。使用项目原 BM25 与 jieba 实现，k1=1.5、b=0.75；IDF 在完整 19367 片段上拟合，与原混合检索组件一致。返回候选仍排除 335 个旧版本片段，只在 19032 个合格片段中选择，年报按公司与年度约束。公开问题直接用作查询，排名 ID 在读取参考答案之前落盘，防止以参考引文构造有利查询。

60 条问题均完成 merged 与 dual 两种检索，每个排序在五种预算下组装，产生 600 个新上下文。此处是新执行的稀疏检索，不是缓存神经排序的再截取；同样没有调用生成器，因此不能拿它替代先前人工评分的 BM25 生成条件，也不能把两套 BM25 条件的数据直接拼成一次端到端实验。 排名和预算回放的来源定位结果见补充表 S2。

补充表 S2 新 BM25 与缓存混合重排在 6000 上限的来源定位代理

检索来源	策略	A 定位覆盖	R 定位覆盖	双参考角色	实际 tokens
缓存混合重排	dual	74.3%	3.9%	10.0%	4032
缓存混合重排	merged	79.7%	0.0%	0.0%	4945
新 BM25	dual	69.0%	33.3%	33.3%	5319
新 BM25	merged	73.0%	30.0%	28.3%	5381

表面上，新 BM25 的法规位置覆盖达到 30.00%和 33.33%，高于缓存混合重排。但逐粒度拆分后，这一改善完全来自整份 TXT 来源匹配：内控 20 题中，BM25 合并和双路分别命中 18/20 和 20/20 个来源；而在 40 个 PDF 法规参考问题上，两个 BM25 策略的页级覆盖均为 0，缓存双路为 5.83%。因此，汇总代理的提高主要反映定位粒度与文档身份，不是 BM25 已经实现更精确的法律段落检索。

这一敏感性实验说明，在混合文档形态的 RAG 评测中，页级与源文件级标注不能无说明地放在一个“检索准确率”中。整份法规文件被检索到，比没有该文件更有利，但不保证返回片段位于相关条文，也不能证明适用版本正确。对于来源单位不同的指标，应保持拆分结果，以免系统因命中较粗的标签而显得更优。 法规页级和文件级定位结果分列于补充表 S3。

补充表 S3 法规定位粒度拆分（PDF 页级：40 题、120 个目标定位；TXT 来源：20 题；分母不同，不直接比较）

方法	策略	PDF 页级覆盖 n=120 个定位	TXT 来源命中 n=20 题
缓存混合重排	merged	0.00%	0 / 20
缓存混合重排	dual	5.83%	0 / 20
新 BM25	merged	0.00%	18 / 20
新 BM25	dual	0.00%	20 / 20

作为替代来源敏感性补充，去除来源身份限制后的法规参考引文 12 字符词面覆盖，在缓存 G1/G2 中分别为 0.59%与 11.88%；G2 有 33 题虽然严格参考位置未命中，但在其他来源或页面出现部分参考措辞。例如规范复述、修订决定与正文重复，都可能导致这种现象。词面重叠不证明法规等价、版本相同或具体论断受支持，因此它只提示严格定位可能漏计替代材料，不能把两种指标加总成语义正确率。

本次对照仍受组件条件限制：缓存混合结果来自已保存神经候选，而新 BM25 重新执行稀疏检索；没有同时重跑完整神经链。已有模型 revision 与原始查询保持记录，供未来在相同机器和同次执行中复核。当前实验的作用是揭示指标、定位粒度与来源供给的关系，不据此宣称一种完整系统胜出。