年报与法规双源检索增强生成的受控评价与证据覆盖分析

Controlled Evaluation and Evidence-Coverage Analysis of Dual-source Retrieval-Augmented Generation over Annual Reports and Regulations

摘要

上市公司评价既需要年报披露，也需要相应法规依据。本文考察在年报与法规问答中，按来源分路检索相较合并检索能否改善回答质量及证据供给。我们构建保留文档身份和原文坐标的双源检索增强生成流程，在 20 家公司 2024 年年报的 60 个问题上比较合并检索、双路检索及相同证据下的来源角色提示。主对照原计划 180 个 Kimi 供应商请求，首轮 147 个结构有效；33 条会话补充回答未执行冻结提示及 API 协议，其中 31 条曾进入旧评分汇总，现全部排除。过滤后保留 355/400 个供应商生成输出的双人评分。G2 相较 G1 在 41 个可配对问题上的 0 至 8 分公司宏均差为 0.228（20,000 次公司聚类 bootstrap 点对点 95%区间[0.110, 0.355]），但全 60 题的缺失数据界跨 0。G3 相较 G2 在 38 个配对问题上的差为 0.013（区间[0.000, 0.039]）。双路检索条件下两类来源同现率为 100%，合并检索条件下为 68.3%；但平均参考位置覆盖未提高，法规参考位置覆盖仍有限。观察到的总分差异主要集中在法规评分维度；引用及不确定性维度存在天花板。结果仅适用于本研究样本、模型和评分协议。

关键词：检索增强生成；年度报告；法规证据；来源追溯；预算回放；人工评价

Abstract

Listed-company evaluation requires both annual-report disclosures and relevant regulatory evidence. This study asks whether source-separated retrieval improves answer ratings and evidence supply over pooled retrieval. We build a traceable dual-source RAG pipeline and compare merged retrieval, dual retrieval, and source-role prompting with identical evidence on 60 questions from the 2024 annual reports of 20 companies. The primary comparison planned 180 Kimi-provider requests; 147 were structurally valid in the first run. Thirty-three session-authored supplements did not execute the frozen prompt or API protocol; 31 had entered the earlier score summary and are now excluded. The filtered set contains 355 two-reviewer-scored provider outputs from 400 planned units. On 41 paired questions, the observed company-macro mean difference between dual and pooled retrieval is +0.228 points on a 0–8 scale (20,000-draw company-clustered pointwise 95% interval: [0.110, 0.355]); however, the missing-outcome bounds for all 60 questions include zero. The observed difference between source-role prompting and dual retrieval is +0.013 points on 38 paired questions (interval: [0.000, 0.039]). Two-source presence was 100% under dual retrieval versus 68.3% under pooled retrieval, while mean reference-location coverage did not improve and regulatory reference coverage remained limited. The observed score difference is concentrated in the regulation dimension; citation and uncertainty ratings show ceiling effects. These findings are limited to the sampled companies, model configuration, observed pairs, and rating protocol.

Keywords: retrieval-augmented generation; annual reports; regulatory evidence; provenance; context-budget replay; human evaluation

1 引言

上市公司评价中的证据具有明确的角色差异。年报记录企业对治理安排、内控事项和分红政策的公开披露，法规文件规定相关主体应当履行的要求。回答“公司披露了什么”与回答“披露是否满足规范要求”所需要的证据并不相同。前者不能仅凭法规推断，后者也不能仅凭公司描述完成。将二者组织为可核查的回答，是面向专业文档问答的一个具体信息处理问题。

传统检索往往把片段按问题相关性放入同一个排序列表，但语义相似度并不编码证据在论证中的角色。某类法规因为包含与问题高度一致的术语而占据前列时，公司特有披露可能被排出上下文；反之，年报

中的政策复述也可能挤占规范原文。有限上下文进一步放大了候选竞争。即使最终答案同时出现公司名称和法规名称，也不能据此确认模型取得并正确使用了两类原文。

RAG 把外部检索与语言生成结合，为知识密集任务提供了可更新的证据接口[1]。然而，检索相关、上下文可用、论断获支持和法规适用是不同层次的问题。增加重排器、提示模型逐条引用或引入多个角色，都可能改变回答，但这些组件各自是否有价值，仍需在相同问题与可比较条件下检验。本文因此将来源分离和角色提示作为两个不同的干预因素。

本文聚焦两个主要研究问题。RQ1：在相同问题、语料和生成配置下，按来源分路检索相较合并检索能否改善回答评分及可审计的证据供给？RQ2：在检索上下文逐字相同的条件下，来源角色提示是否带来额外评分收益？预算回放、BM25 对照、来源删除和同系列服务版本分析用于补充解释，详见补充材料；这些探索性分析不作为主文的独立研究问题或普遍性结论。

本文的工作包括：构建保留文档身份、物理位置和实际提示记录的双源 RAG 流程；通过 G1 合并检索、G2 双路检索和相同检索证据下的 G3 角色提示，分别考察检索组织与提示的作用；在 20 家公司 60 题和双人评分上报告公司聚类配对分析，并区分两类来源是否供给、目标位置是否覆盖和回答评分。本文不把现成组件组合宣称为新检索算法，也不以引用编号有效替代语义支持。

在当前受控比较中，双路检索相对合并检索呈现正向评分差异，而同上下文的角色提示未显示稳定增益。主文据此讨论来源组织与证据覆盖之间的关系，并明确结果仅适用于本研究的样本、模型配置和评分协议。配置简化、来源删除、预算及排序诊断等扩展分析置于补充材料，保留其探索性定位、负结果与失败记录。系统流程见图 1。

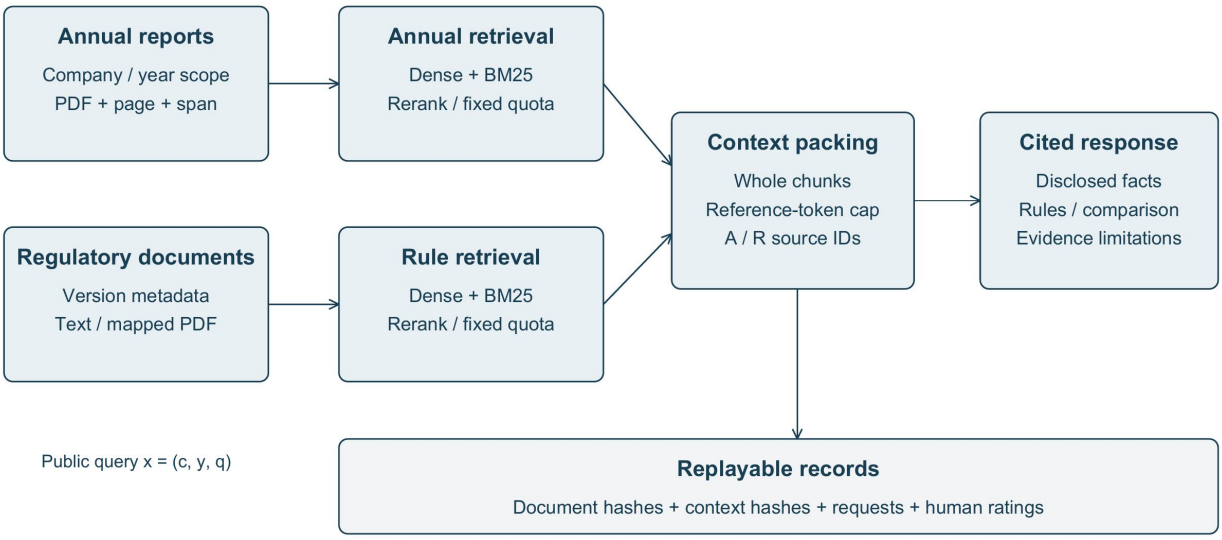


图 1 系统流程与可回放记录。年报和法规独立限定作用域，经检索、重排与整块预算组装形成实际上下文；来源坐标不等于语义支持。

2 相关工作与研究定位

2.1 金融文档问答与领域证据

FinQA 聚焦金融数据中的数值推理[2]，TAT-QA 研究表格与文本混合内容上的问答[3]。二者表明，财务报告中的证据结构与一般开放域文本不同，但其任务目标并不等同于公司披露与规范依据的联合评价。HiREC 通过层级检索和证据整理处理标准化金融文件[4]，直接说明年报检索、长文档组织与补充查询本身已有先行研究。

近期年报问答基准进一步检验了表格、正文与答案证据的联合组织。ARQA 覆盖十个财年汽车企业年报，提供约 2,500 条查找、计算与洞察类问答；题目经过确定性校验与重算，并由领域专家审核[28]。中文 CFQA 以 50 家上市公司 2023—2025 年年报构建 500 题，人工标注并绑定原文，再比较 RAG 与无检索基线，同时区分答案匹配与证据支持/编造[29]。这些工作聚焦年报内部问答基准；本文研究的是公司披露与独立法规证据的联合评价，并在已有 20 家公司 60 题的双人评分上区分来源分路与提示约束。本文不将金融文档检索或年报 QA 基准构建本身宣称为独立创新。

Siddharth 与 Luo 从工程文档中提取显式事实供生成使用[5]，Yang 等梳理了语言模型与知识方法的结合[6]。本文选择直接以文档及其坐标作为运行输入，避免要求先建立穷尽的公司事实库。参考事实与证据用于离线评价，而非先把答案编码进运行时知识库。此差异使检索误差、解析误差和生成误差能够分别检查。

2.2 稀疏稠密检索与领域增强

BM25 以词项匹配提供稀疏检索信号[7]，DPR 等方法学习稠密表示以缓解词面差异[8]，Qwen3 Embedding 系列进一步提供嵌入与重排模型[9]。不同检索信号的互补性不等于其在所有领域都能提升端到端质量。混合分数的尺度、候选组成及下游生成器都会影响结果，因此本文同时保留仅 BM25 与去重排条件。RRF 提供基于名次的融合思路[10]，但本轮主配置使用固定加权融合，不把未运行的 RRF 写成实验结果。

Alier 等针对教育语料中的缩写检索困难，分别研究查询时与入库时增强，并分析组件、误差和部署成本[11]。这类领域化研究提示，应先识别真实检索失败，再验证干预环节。本文的领域因素是两类资料承担不同证据角色，新增回放用于测量材料供给的变化，而不直接把位置命中解释为完整语义支持。

2.3 迭代检索与智能体协作

Self-RAG 通过检索和自反思机制改进证据使用[12]，CRAG 引入对检索质量的纠正处理[13]，Adaptive-RAG 根据问题复杂度选择检索策略[14]。AIR-RAG 研究迭代检索与生成器对齐[15]。这些方法提供了更强的自适应基线方向，但其中的训练目标、控制器或推理流程不能用一句“请反思”替代。本文没有复现这些训练型方法，因此在相关工作中讨论，在实测表中不填写其性能。

ReAct 把推理与外部动作交错组织[16]；CoLE 借鉴法律专家的分工构造提示流程[17]；MADKE 通过共享外部知识辅助多智能体辩论[18]。本文当前实现是固定的双源检索与生成编排，来源角色提示也只是提示干预，不具备自主工具规划或多智能体通信。区分这些实现边界，能够防止把模块数量、来源数量和智能体数量混为一谈。

2.4 引用评价与专业任务有效性

ALCE 将生成与引用质量纳入评价[19]；RAGAs 提供自动化评价方法[20]；RAGChecker 进一步分解检索和生成环节[21]。这些研究共同说明，答案表面质量和引用可解析性不足以解释完整 RAG 表现。本文将请求成功、结构有效、来源可回放、人员质量评分和法规适用性分开报告，且不把模型自报的支持状态用于替代人员判断。

LegalBench-RAG 强调在法律文档中定位相关证据片段[22]，长上下文研究则显示信息的长度和位置可能影响模型利用能力[23]。本文现有参考标签主要在页面与要点层次，不是穷尽的最小片段相关性标注，因此新增检索分析使用严格来源与页码位置代理，避免套用标签条件不成立的标准 Recall 或 nDCG。法规时点适用需要事项时间和规范版本证据，仍不能仅靠检索相关来确认。 代表性研究与本研究的差异归纳见表 1。

表 1 代表性研究与本研究的区别

研究	主要处理对象	本文采用或比较的边界
FinQA / TAT-QA [2,3]	金融报告数值与混合内容问答	任务相关；本研究聚焦披露与规范联合依据
ARQA / CFQA [28,29]	年报表格—文本 QA 基准与答案证据评估	聚焦年报内部问答；本文补充法规来源角色与来源组织对照
HiREC [4]	金融文件层级检索与证据整理	不将金融检索本身宣称为新方法
领域知识 RAG [5,6,11]	领域知识表示与检索增强	借鉴组件控制；不复制本体或知识图谱
Self-RAG / CRAG [12,13]	自反思或纠正检索	未忠实复现；不填入性能对照表
Adaptive-RAG / AIR-RAG [14,15]	自适应与迭代检索	作为后续强基线，当前仅固定检索
CoLE / MADKE [17,18]	法律专家提示与知识增强辩论	当前系统不称为多智能体
ALCE / RAGAs / RAGChecker [19–21]	引用与细粒度质量评价	区分结构、语义和实际人员评分
LegalBench-RAG [22]	法律片段证据定位	本研究页级标签不冒称穷尽片段 qrels

3 双源检索与可追溯生成方法

3.1 输入输出与研究对象

设公司标识为 c，报告年度为 y，评价问题为 q，公开输入为 x=(c,y,q)。文档库由年报集合 D_A 和法规集合 D_R 组成，来源函数τ(d)取 A 或 R。输出包含回答 a、实质论断集合 C、论断与实际证据编号之间的关联，以及材料不足或冲突说明。本文的评价单位是给定问题的文档依据回答，不是对公司真实治理水平的无条件评级。 符号及其含义见表 2。

年报对公司事实提供披露层面的依据。某项事项未被解析到、没有被检索到或没有在给定片段中出现，都不能推出事项本身不存在。规范性论断需要核对法规原文，将公司披露与规范要求比较时还需确认两者的实体、主题和时间条件可比。资料不齐时允许保留未知，不能强制输出合规结论。

表 2 符号与含义

符号	定义
x=(c,y,q)	公司、报告年度和评价问题
D_A(c,y), D_R(q)	年报和法规的合格检索作用域
H_A,H_R,H_M	两类独立候选与合并候选序列
K_A,K_R,K	来源候选配额及总上限
B,T(E)	上下文参考 token 上限及计数
E_M,E_D	合并检索与双路检索实际上下文
C,L	实质论断集合及论断—证据关联
Q_i,Δ_c	回答探索性质量总分及公司内配对差

3.2 文档身份与位置表示

每份文档首先登记来源、公司及年度、全文或摘要身份、版本信息和文件 SHA256。年报 PDF 按物理页建立文本帧，片段保存文件哈希、页面文本哈希、从 1 开始的物理页序及字符起止区间。印刷页码和阅读器物理页序分别处理，不通过文件名推测页码。OCR 文字保留其解析来源及未核实状态，原 PDF 保持不变。

法规来源按其真实文件形式定位。文本法规保留原文件哈希与字符区间；可映射到 PDF 的来源另保留物理页及页内位置。跨页条款需要逐段位置，而不能为整个条款编造一个“正确页码”。发布日期、生效日期、失效日期和事项日期是不同字段，缺失值不以本地修改时间或报告年度补齐。

位置记录解决“模型看到了哪段材料”的回放问题，并不自动解决该段是否支持论断。本文把来源解析视为语义审计的前提条件，而非替代条件。哈希相同只能证明字节身份一致；即使原文可靠，同一句话也可能因主体、时间或例外条件不同而不适合用于当前评价。 来源记录字段及其核验层次见表 3。

表 3 来源记录与各检查层次

记录或检查	保存内容	能够说明的范围
文件身份	来源、版本、SHA256	文件字节与声明身份的关联
PDF 位置	物理页、文本帧哈希、字符区间	片段可以回到实际页面
文本法规	文件哈希、条号与字符区间	不伪造 PDF 页码
上下文回放	实际片段 ID、prompt/context 哈希	实际提供给模型的材料
引用 ID 校验	引用是否来自提供的 ID 集合	仅结构可解析
人员原文评分	事实、法规、引用和不确定性	探索性质量判断
时点适用	事项日期、有效期间及版本	需独立证据；本轮未全面验证

3.3 双作用域检索与固定融合

年报作用域 D_A(c,y)由公司和报告年度限定；法规作用域 D_R(q)由文档类型及实际配置允许的时间元数据处理限定。两种策略使用相同的可用来源范围，避免将“多了一份正确资料”与“换了排序方法”混为一谈。默认检索模型为 Qwen3-Embedding-0.6B，重排模型为 Qwen3-Reranker-0.6B，文档编码不混入查询提示，查询使用固定任务指令。本轮 60 题均没有提供独立事项日期，系统不从 2024 报告年度推断日期，全部 5994 个法规片段按 unknown=retain 保留，时点排除数为 0。因此不能把本轮结果归因于有效时点过滤。

稠密与 BM25 信号使用固定配置融合，主配置稠密权重为 0.7、稀疏权重为 0.3。该数值是原型参数，不是通过本轮测试集证明的最优权重。候选重排后进入上下文组装。本文后续不根据测试结果回调这些参数，也不将未检验的权重变化写成改进。具体实现先各召回 2×top-k，在各通道返回集合中除以该通道最大分数（最大值为 0 时以 1 代替），对并集用 0.7/0.3 加权，再取最多 4×top-k 进入重排，重排 max_length 为 3072。实际候选数受通道并集大小限制；此处为最大值归一化而非 min-max 归一化。

G1 把两类资料的合格片段放在共同候选池，取总候选上限 10；G2 在年报和法规作用域各取最多 5 个候选，再按现有确定性规则合并与组装；G3 直接复用 G2 组装后的上下文。双路并不保证所有问题都取得足量年报证据，原因包括上游召回不足、片段过长和总预算裁剪。新增回放实验直接测量这些条件。

3.4 上下文组装与可比较性

设候选序列 H=(h_1,…,h_K)，T 为冻结的参考分词器，B 为上下文上限。组装器按既定顺序访问候选：若加入完整片段后|T(E⊕h_i)|≤B，则保留，否则跳过该片段继续检查后续候选。重复片段 ID 被拒绝，片段文本不截断；最终记录实际保留、跳过原因和上下文哈希。

这种 whole-chunk 策略避免把引用位置与截断后的残句混淆，但会带来预算未完全填满和来源数量变化。候选配额是进入组装器的上限，不是最后上下文中两类来源的保证。某个长年报片段被跳过后，后续短法规可能仍能进入，这种供给变化需要通过实际 tokens、片段数量和位置覆盖共同描述。

主对照使用总计 6000 参考 tokens 上限。相同上限不等于相同实际 token 数，也不等于同等服务端费用；参考分词器与 API 供应商分词器未验证一致。本文因此将“预算匹配”限定为共同的参考上限，并在新分析中报告实际用量与延迟，不把上限相同表述为计算量完全相等。

G1: E_M=Pack_B(Top_K(D_A(c,y)∪D_R(q)))； G2: E_D=Pack_B(Merge(Top_KA(D_A), Top_KR(D_R)))。

G3: E_role=E_D；a_generic=LLM(P_generic,E_D)，a_role=LLM(P_role,E_D)。

上述等式描述实现中的条件控制关系，不是额外训练目标。候选排序、片段长度和访问顺序共同决定最终 E，因而即使 K_A=K_R，也须检查 Pack 后的来源数量。

3.5 引用约束与来源角色

G1 和 G2 都要求实质论断给出实际提供的证据 ID、claims 及 citations，并共同包含不得凭记忆补充事实和法规、材料不足时说明限制等要求。因此，G2 相对 G1 的差异主要对应检索组织变化，不能表述为“无引用”到“有引用”。G3 增加事实论断用年报、规范论断用法规以及比较性评价需要相应证据链的要求。

G2 与 G3 的上下文和来源记录逐字一致，隔离的是提示约束的增量作用。模型返回的 claims 和 evidence_status 仍属于模型输出。结构检查只检验必需字段、证据编号可解析与数据类型，不将模型写出的 supported 视为经核验的支持标签。真正的质量分析以两位人员对原文的独立评分为依据。

来源角色可表示为论断—证据二部关系。事实论断与 A 类片段相连，规范论断与 R 类片段相连，比较性论断可以连接两类片段，但仅有两条连线并不能证明比较成立。还必须检查原文是否相互匹配、是否支持同一事项，以及事项日期与规范版本是否具备足够依据。本文没有训练一个能够自动认证这些关系的判别器。 论断与来源关系示意见图 2。

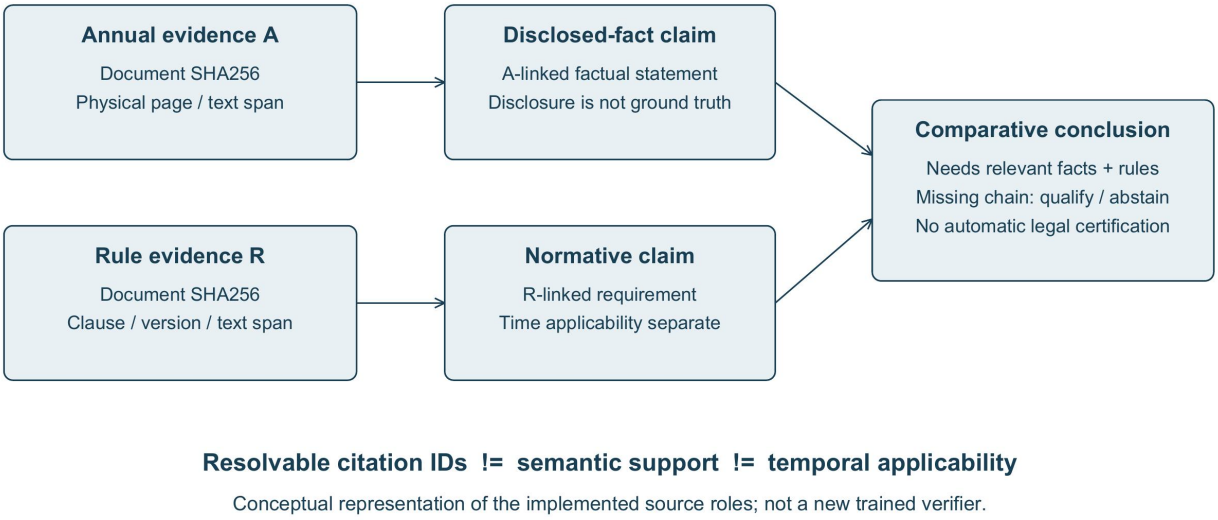


图 2 论断—来源关系与核验层次。比较性结论需要相应事实与规范，但编号连线本身不证明语义支持或时点适用。

3.6 复杂度与运行记录

令两个作用域候选数量分别为 N_A、N_R，查询向量维数为 d。对缓存向量直接计算相似度的矩阵运算与(N_A+N_R)d 成正比；BM25 评分和重排开销另计。G1 和 G2 的候选池组织不同，可能产生不同的上游召回与重排调用量，不能仅因最终候选上限相同就认为检索成本相等。本文的实测运行开销来自保存日志，回放时间不作为神经检索时间。

实现保存文档、索引清单、输入上下文、请求参数及响应的分层记录，使数据变化与推理变化可以分别追踪。完整原始响应、结构失败与一次恢复视图均保留；API 密钥不进入论文或材料包。新增分析使用新的目录和脚本，不覆盖先前评分、运行或论文版本。

4 数据与实验协议

4.1 文档库与问题集合

本文区分系统可检索文档库与用于评分的问题集。新增检索审计在冻结索引中识别到 39 份年报的 13038 个片段，以及 87 份法规来源的 5994 个片段，合计 19032 个合格片段。它们是按类型和系统输入标记筛选后的实际作用域，不与早期先导运行中的其他文档数或片段数混用。87 份法规来源中可能包含文本与 PDF 形式，物理页字段的可用性也不同。

人员评价使用 20 家公司 2024 年年报对应的 60 题，每家公司三个主题：审计委员会、内部控制与分红披露。该组合使同公司题目相关，不能将 60 题当作 60 个独立公司。题目有 180 个参考要点、123 条去重参考证据及 256 次问题—证据关联。参考证据不是穷尽的所有支持材料，而是已复核的目标原文。 语料范围和标注构成汇总见表 4。

表 4 语料与标注范围

对象	数量	解释
合格年报库	39 份 / 13038 片段	39 个来源哈希，全部有物理页
合格法规库	87 份 / 5994 片段	87 个来源哈希；289 个片段有物理页字段
质量问题集	20 公司 / 60 题	2024 年；3 主题各 20 题
参考要点	180	问题级评分依据，非穷尽公司事实库
参考证据	123 条 / 256 次关联	122 条 PDF 参考与 1 条 TXT 参考的定位均在索引中存在
全条件供应商输出评分	355 回答 × 2 人 × 4 维	2840 个 0/1/2 评分值；33 条会话补充输出不纳入，其中 31 条曾进入旧版评分汇总

4.2 比较条件与变量隔离

主对照在 60 题上执行 G1、G2、G3，共 180 个计划单元。G2 与 G3 共享完全相同的证据，隔离提示约束；G1 与 G2 的合格来源范围、总候选配额和参考上限一致，但实际候选组成和 token 长度可能不同。去重排和仅 BM25 各 60 个单元，保留角色约束作为检索配置对照。

来源缺失在预先确定的每公司一题上分别删除全部年报或全部法规片段，共 40 个单元。保留剩余片段的文字与编号，不重新检索。删除同时改变信息内容与实际长度，因此它测量的是当前输入中一类资料的缺失反应，不是纯角色标签效应，也不等价于一般噪声鲁棒性。

同系列服务版本比较在同一 20 题上各执行三条件，共 60 个单元。供应商资料将 kimi-for-coding 对应为 K2.8 Preview [24]；两个服务别名的底层 checkpoint 均未独立验证。K3 与 kimi-for-coding 请求均未发送 reasoning_effort 参数。供应商 2026-10-20 说明将两者默认档位分别列为 high 和 max，但响应未记录可独立核验的服务端实际档位。因此本比较未统一推理预算，不能解释为等预算的模型权重比较，也不是跨厂商模型族泛化。 实际比较条件与分析范围见表 5，变量隔离示意见图 3。

表 5 主文与补充分析范围

分析	计划规模	主要控制与边界
主文 主对照	60×3=180 回答	G1/G2/G3；仅计冻结供应商调用输出
补充 检索消融	60×2=120 回答	去重排、仅 BM25；非所有配置全面因子设计
补充 来源缺失	20×2=40 回答	删来源不重检索；信息与长度同时变化
补充 服务版本	20×3=60 回答	同系列别名；思考预算未显式统一
补充 预算回放	60×2×3×5=1800 上下文	固定候选排序；非 1800 条新生成回答

分析	计划规模	主要控制与边界
供应商输出评分与稳健性诊断	355 输出 / 400 计划单元	排除 33 条会话补充回答；355 条供应商输出由两人评分
补充 BM25 重跑	60 题×2 策略	完整合格作用域 CPU BM25；与缓存神经候选分开解释

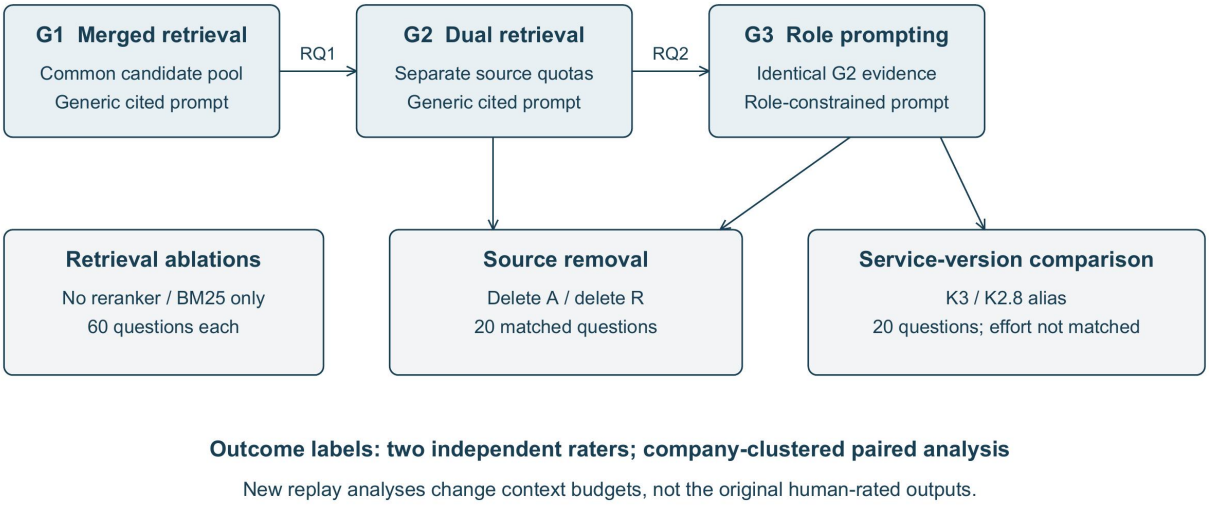


图 3 变量隔离与扩展实验设计。回放改变候选配额和组装预算，不改变历史评分输出。

4.3 实现参数与执行失败

检索 Embedding revision 固定为 97b0c614be4d77ee51c0cef4e5f07c00f9eb65b3，Reranker revision 固定为 e61197ed45024b0ed8a2d74b80b4d909f1255473。默认本地 CUDA、float16、batch size 为 1，硬件为 GTX 1660 Ti；文件、哈希、BM25 与统计使用普通 CPU 处理。生成由远程 API 完成，本机 GPU 配置不决定服务端生成速度。

主生成 temperature 为 1，最大输出 16384 tokens，请求超时 600 秒，SDK 自动重试为 0，每个题目—条件执行一次主请求。调度随机种子 42 没有发送为生成随机种子，不能据此宣称可精确复现采样。准备阶段因供应商参数限制或截断发生的请求设置修订及错误回执均保存。首轮 180 个主对照请求中 147 个结构有效、33 个失败。随后保存的 33 条补充回答由当前助手会话撰写，未执行冻结提示，新增供应商 API 调用为 0；31 条曾被双人评分，2 条未评分。因生成来源和协议不同，33 条均从受控比较及全条件统计中排除。

4.4 双人评分与可测量内容

两位人员分别对实际回答核对原文。主对照仅纳入 147 条首轮供应商 API 结构有效输出；所有实验条件过滤后共保留 355 条供应商输出的双人评分。评分包含公司事实、法规依据、引用支持和不确定性处理，每维 0、1、2 或 U。只有两人四维均为数值时计算均分总量 $Q_i=(1/2)\sum_r\sum_j s_{irj}$，范围 0 至 8。本轮纳入评分的输出没有 U；失败与未运行不填质量 0 分。均分是分析指标，不是分歧裁定或一致金标。

每个分数表示对该回答在所用简化量表下的判断，不对应公司治理分数，也不是经过概率校准的合规准确率。引用项是回答层面的粗量表，不能推导逐论断完整归因或原 H1/H2 定义的联合成功率。原始评分、复核说明与分歧保留，新增分析没有更改任一人的分值。

输出评分与题目标注的复核是不同过程。参考材料的两名既有复核人员与最终两份输出评分分别登记。项目负责人已更正早期 AI 辅助身份标识并确认两份评分由人员核对原文，本文沿用验收记录而不添加不存在的裁定过程。两人均分和评分者敏感性方案在评分可见后决定，因此属于探索性分析。

4.5 配对估计与缺失敏感性

对同一问题匹配两个条件，先计算每家公司内可观测配对差值，再对公司等权平均。本文报告的供应商输出重分析主比较、逐维度及主题诊断均按公司为重采样簇进行 20,000 次 percentile bootstrap（seed 20261028），报告探索性点对点 95%区间；不作多重比较校正。区间以可观测配对为条件；缺失配对另以 0 至 8 分量表端点计算全 60 题代数界，二者估计对象不同。

公司聚类考虑了同公司三题相关，但不能消除共有法规造成的跨公司依赖。新增逐公司删一分析检查观察差异是否依赖单个公司，完整题和完整公司分析检查在共同成功子集上的方向。它们都不等同于处理了所有缺失偏差，也不使原问题变成未见测试。

缺失敏感性另报告全计划问题均差的代数界。若同题两侧均已知，贡献为 q_t-q_b；若只有处理侧缺失，贡献区间为$[-q_b,8-q_b]$；若只有基线缺失，则为$[q_t-8,q_t]$；两侧均缺失时为$[-8,8]$。将各题区间端点求均值获得保留已知单侧的锐界。该量是问题加权，不是公司宏均值的置信区间，不能与 bootstrap 区间混称。

4.6 来源供给与检索诊断

主文仅报告主实验的来源供给与目标位置代理。依据 60 题 merged/dual Top-10 保存排序，按参考证据的原始文件身份和页码计算双源共现、来源均衡与严格位置覆盖；文件级 TXT 参考与 PDF 页级参考分开报告。指标表示候选或参考位置是否匹配，不判断片段语义支持、等价替代或法规时点适用。主实验排序没有同题相关性金标准；独立 40 题开发集 qrels 与主实验题目 ID 无交集，因此不计算标准 Precision@k、Recall@k 或 nDCG@k。候选预算回放和重新执行 BM25 的方法与结果见补充材料 S1–S2。

5 主实验与评分诊断

5.1 运行覆盖与质量分布

400 个计划供应商请求中，主对照首轮 147 个、检索消融 109 个、来源缺失 40 个、同系列第二版本 59 个，共 355 个结构有效输出且取得双人评分。另有 33 条会话补充回答，其中 31 条被旧评分清单收录；它们未执行冻结的 Kimi 提示和 API 协议，现已排除。排除补充回答后，45 个计划供应商单元没有合格输出。有效表示供应商返回且通过结构检查，不表示事实、引用或法规适用性正确。

表 6 各条件可用输出数与回答级双人均分

条件	可用/计划	双人均分	人员 1	人员 2
G1	52/60	7.327	7.577	7.077
G2	47/60	7.543	7.809	7.277
G3	48/60	7.594	7.833	7.354
No rerank	55/60	7.809	7.855	7.764
BM25	54/60	7.852	7.704	8.000

条件	可用/计划	双人均分	人员 1	人员 2
No annual	20/20	6.675	7.000	6.350
No regulation	20/20	6.925	6.850	7.000
K2.8 G1	20/20	7.325	7.500	7.150
K2.8 G2	19/20	7.579	7.789	7.368
K2.8 G3	20/20	7.600	7.850	7.350

表中各条件使用的问题子集和缺失不同，不能按非配对均分排序推断方法优劣。尤其是模型版本比较与来源缺失只使用 20 题，和 60 题总体条件不构成直接可比的全样本排名。BM25 条件中人员 2 对全部 54 条输出给出满分，提示尺度分辨能力与评分者差异必须单独检查。

5.2 双路检索与角色提示的增量

在纳入的供应商输出中，G2−G1 的 41 个已知配对问题公司宏差值为 0.228，20,000 次公司聚类 bootstrap 点对点 95%区间为[0.110, 0.355]；G3−G1 为 0.289（42 对，[0.158, 0.430]）。G3−G2 仅有 38 个配对，差值为 0.013（[0.000, 0.039]），其中 1 题 G3 较高、37 题相同、没有观察到 G3 较低。区间以可用配对为条件，不校正多重比较，也不是预注册检验。由于 G2/G3 缺失较多，不能据可用配对区间推断全 60 题都存在正向收益；表 10 的全题缺失界均跨零。

表 7 主比较与检索基线对照的公司宏差值及点对点 95%区间

比较	已知/计划	公司宏差值	点对点 95%公司聚类区间
G2-G1	41/60	0.228	[0.110, 0.355]
G3-G2	38/60	0.013	[0.000, 0.039]
G3-G1	42/60	0.289	[0.158, 0.430]
G3-NoRerank	45/60	-0.222	[-0.310, -0.130]
G3-BM25	45/60	-0.245	[-0.343, -0.157]

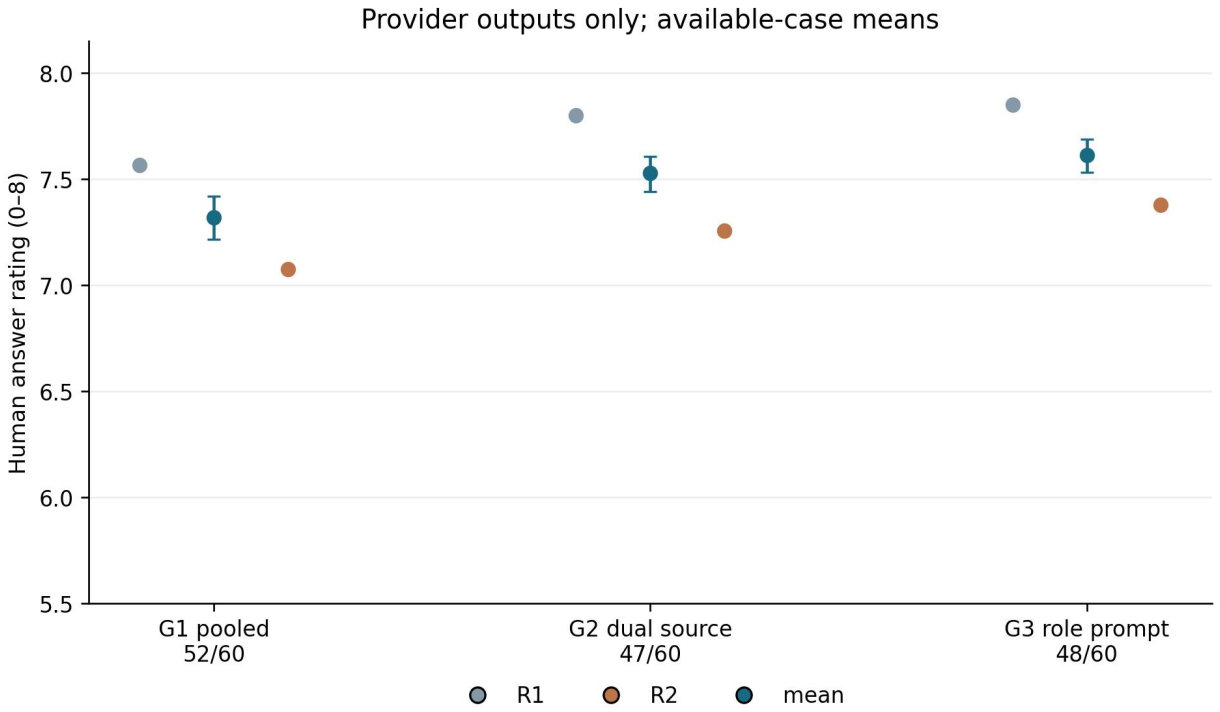


图 4 三个主条件的供应商输出评分与评分者差异。均值及点对点 95%区间仅基于各条件可用输出，区间按公司聚类。

5.3 逐维度分析

在可配对的供应商输出中，G2−G1 的公司宏维度差异为：公司事实−0.009、法规依据+0.237、引用支持 0.000、不确定性 0.000，总分差+0.228。因此观察到的总分差主要集中在法规评分维度，不能改写为各方面质量普遍提高，也不能把法规评分变化解释为时点判定正确率。

G3−G2 的总分接近 0，也不意味着所有题目上行为相同：提示可以增加或改变模型的论断与引用结构，却未必改变人员的粗粒度评分。新增分析将这种表述变化与语义质量分开，避免把更多引用或更长回答当作更准确。 逐维度配对效应见表 8 和图 5。

表 8 双人均分的维度配对效应 每维 0 至 2 总分 0 至 8

比较	配对数	事实Δ	法规Δ	引用Δ	不确定性Δ	总分Δ
G2-G1	41	-0.009	0.237	0.000	0.000	0.228
G3-G2	38	0.000	0.000	0.013	0.000	0.013
G3-G1	42	-0.009	0.285	0.013	0.000	0.289

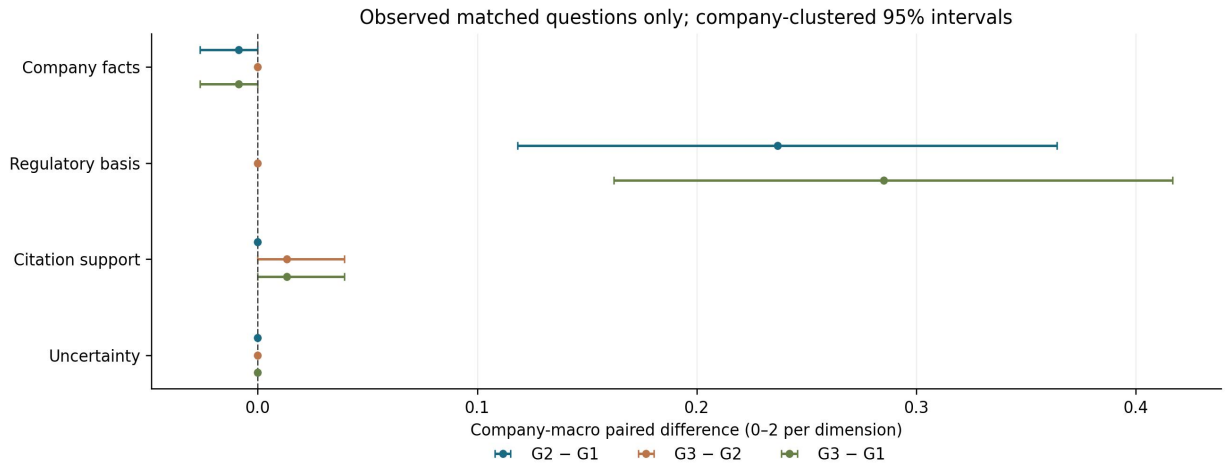


图 5 主比较的公司宏维度配对差。区间为 20,000 次公司聚类 bootstrap 点对点 95%区间；仅包括已观察配对，不作多重比较校正。

5.4 评分者差异与量表天花板

过滤后的 355 条供应商回答共 1420 对逐维度评分，精确一致率为 86.20%（公司事实）、57.75%（法规依据）、97.46%（引用支持）和 100.00%（不确定性）。法规项二次加权κ约 0.215；人员 2 的法规分相对人员 1 平均低 0.417，显示评分尺度或判断存在差异。均分能够对称保留两人的信息，但不能将这种差异自动变成共识。

引用支持的精确一致率为 97.46%，κ为 0；不确定性评分在 355 条回答上两位人员均给出 2 分，故κ因恒定边际不可估计。高一致率伴随近满分分布，不能据此宣称逐论断测量可靠。本文不选择“方法完全相同”或“量表缺乏分辨率”中的任一种作为已证实解释。

表 9 评分者尺度诊断

维度	精确一致率	加权κ	R2−R1 均差	R1 满分率	R2 满分率
公司事实	86.2%	0.400	0.115	81.4%	93.0%
法规依据	57.7%	0.215	-0.417	86.5%	44.8%
引用支持	97.5%	0.000	0.025	97.5%	100.0%
不确定性	100.0%	不可估计	0.000	100.0%	100.0%

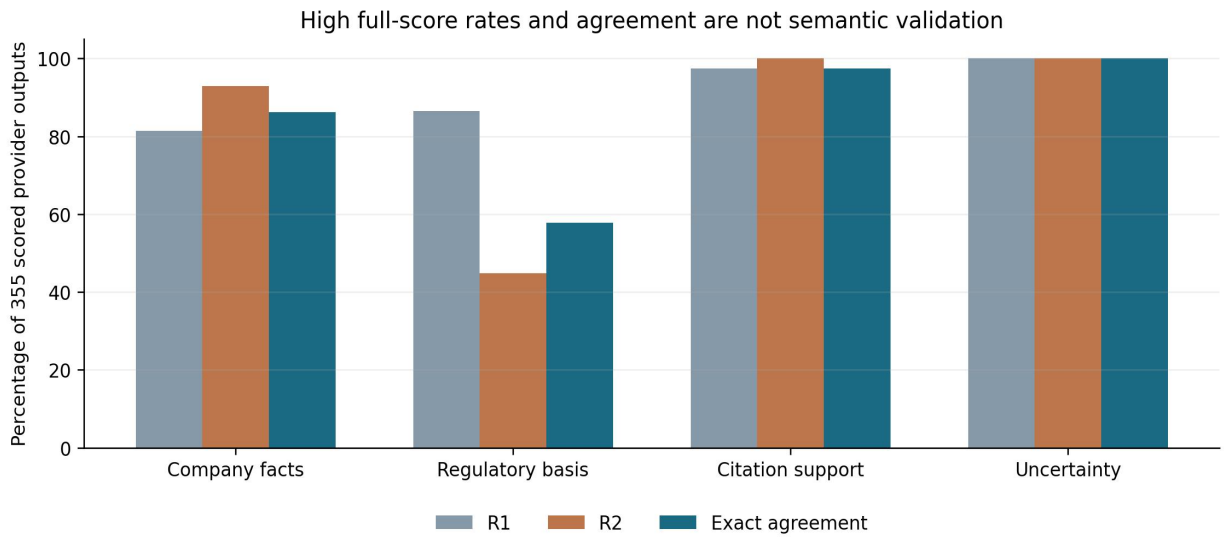


图 6 355 条供应商输出上的评分天花板与评分者满分率。高一致率不代表逐论断语义支持已核验。

5.5 完整样本与缺失敏感性

逐公司删一分析中，G2−G1 的范围为[0.199,0.241]，G3−G2 为[0.000,0.014]。三个主条件均有输出的共同子集包含 33 题、18 家公司，G2−G1 为+0.236，G3−G2 为+0.014；五种检索方法均有输出的共同子集仅含 30 题、16 家公司，相应差值为+0.203 和+0.016。若进一步要求整家公司三个问题全部可用，样本缩至 12 题、4 家公司，G2−G1 为+0.125，G3−G2 为 0。以上均为按可用供应商回答筛选的事后子集，不能消除选择偏差；尤其 12 题、4 家公司的结果不足以支持跨公司泛化。

排除会话补充回答后，G2−G1 只有 41/60 个可配对问题。利用每题可观察的一侧并对缺失评分按 0 至 8 取界，其全题均差范围为[-1.508, 1.292]；G3−G2 为[-1.567, 1.767]。两者均跨零，因此当前可用样本的正向公司聚类区间不能外推为全计划问题上的确定优势。此类范围是基于量表端点的代数缺失界，不是置信区间。逐公司删一范围与缺失界见表 10 和图 7。

表 10 逐公司删一与已知单侧缺失界 量尺与估计对象分别说明

比较	删一公司宏差范围	全清单题均差锐界	胜/平/负题数
G2-G1	[0.199, 0.241]	[-1.508, 1.292]	13/28/0
G3-G2	[0.000, 0.014]	[-1.567, 1.767]	1/37/0
G3-NoRerank	[-0.250, -0.196]	[-1.750, 0.517]	2/23/20
G3-BM25	[-0.260, -0.219]	[-1.792, 0.608]	10/6/29

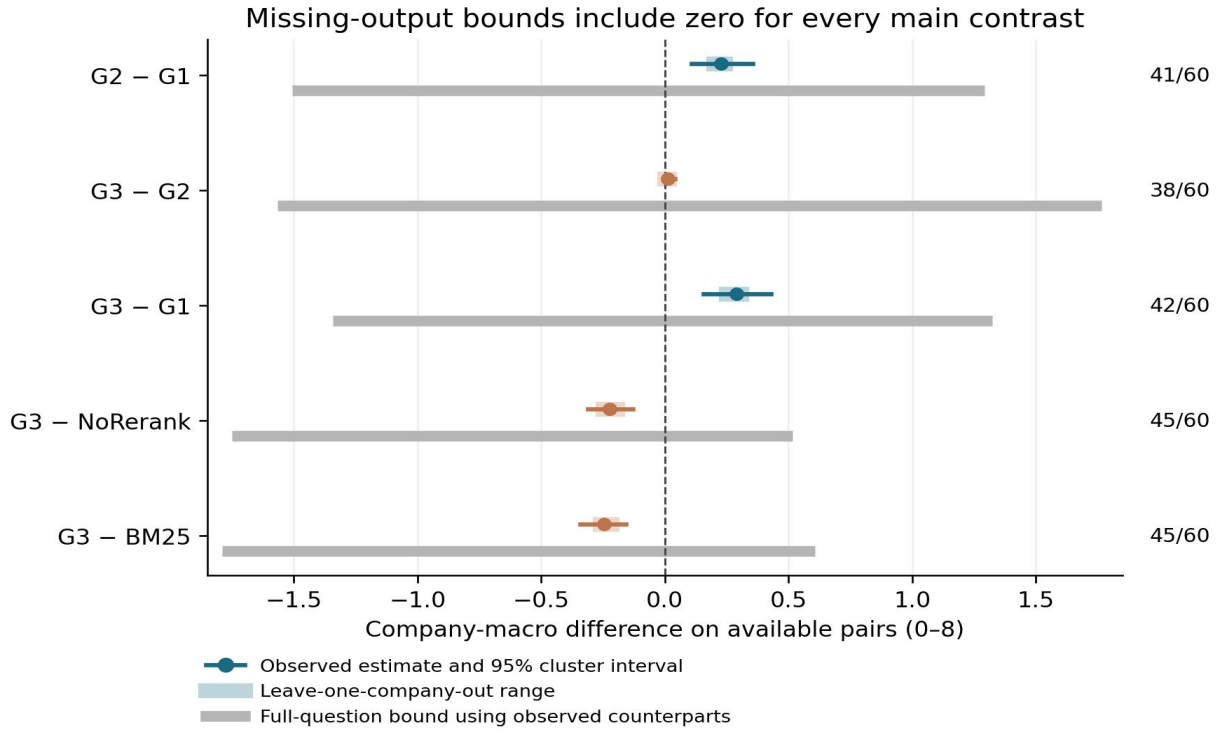


图 7 排除会话补充回答后的缺失与逐公司删一敏感性。观测效应区间为 20,000 次公司聚类 bootstrap 点对点 95%区间；全题代数缺失界与置信区间是不同估计对象。

6 检索证据与案例分析

6.1 来源供给与目标定位覆盖

原配置回放显示，G1 平均保留 8.183 个年报与 1.183 个法规片段，双角色出现率为 68.3%；G2 保留 5+5 片段，出现率为 100%。G1 的 6000 上限下实际参考 tokens 均值约 4945，G2 约 4032，说明相同上限下的实际上下文并不等长。此处观察到的主要竞争是年报占据更多候选，而非预设某一种来源必然主导。更细的候选预算、BM25 与定位粒度、结构引用和调用资源诊断见补充材料；这些分析用于解释运行边界，不与主实验评分合并。

但来源平衡没有转化为目标位置总体覆盖优势。G1 与 G2 的年报页面覆盖均值分别为 79.67%与 74.33%，法规定位分别为 0 与 3.89%，两角色平均 39.83%与 39.11%。同时至少命中两类参考页面的题目从 0 增至 6/60。由于严格来源哈希不合并等价法规形式，这些数值不代表“只有 3.89%的法规相关”，也不代表穷尽相关证据召回率。 来源供给及严格目标位置结果见表 11 和图 8。

表 11 原配置回放来源供给与严格目标位置代理

策略	A/R 片段均值	实际 tokens	双角色出现	A 页覆盖	R 定位覆盖	角色宏覆盖
dual	5.00 / 5.00	4032	100.0%	74.3%	3.9%	39.1%
merged	8.18 / 1.18	4945	68.3%	79.7%	0.0%	39.8%

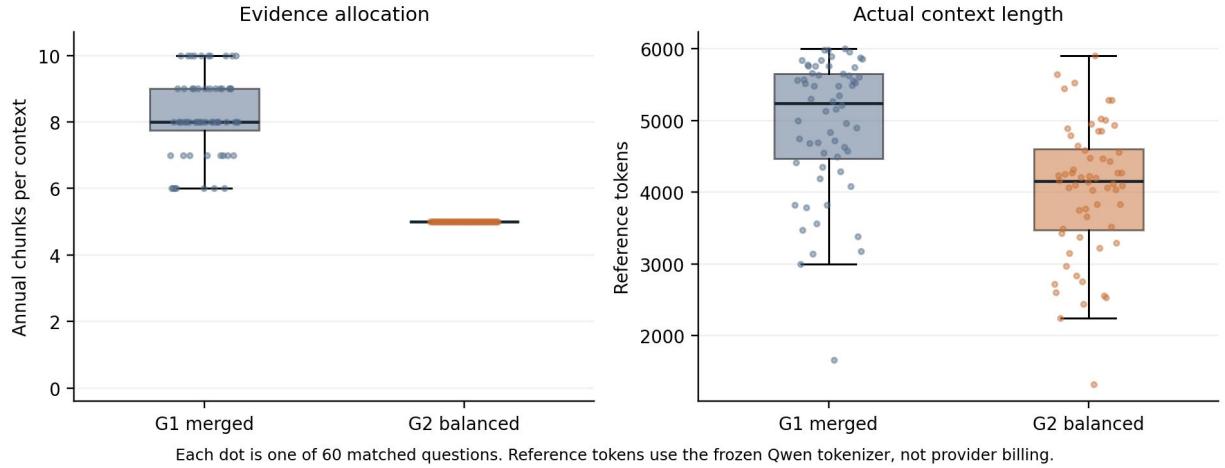


图 8 来源分配回放。类型同时存在是供给指标，不能替代参考页面覆盖或语义支持。

6.2 真实案例与分歧分析

案例按已观察分差事后选择，不具有随机代表性。正向案例为科大讯飞审计委员会题，两人均将法规项由 1 提高到 2，对应 G1=7、G2=8、G3=8；复核说明指出 G1 没有 R 类法规原文。该案例与来源供给不足的解释一致，但不是对全部题目因果机制的证明。

作为一项事后选取的供应商生成案例，立讯精密审计委员会问题在 G1、G2、G3 下的双人均分分别为 7.0、8.0、8.0。G3 输出依据年报报告成员、会议次数和履职情况，同时指出现有年报未逐一说明成员董事类别及召集人身份，且法规文本时点未核验，故不能仅据该回答认定符合规范。该单例用于展示输出与评分边界，不是主效应的独立证据。

在该案例中，G2 与 G3 使用逐字相同的检索上下文且评分相同；它说明角色提示没有在此题增加评分，不能据一个案例推断提示普遍无效。案例和评分均来自主协议下的供应商输出，已排除会话补充答案。

表 12 事后选取的供应商输出案例

问题	三条件分数	G3 正文节选	G3 引用 ID 节选
002475SZ-2024-AUDIT_COMMITTEE	7.0/8.0/8.0	一、年报披露（有原文支持）： 1. 人员构成：立讯精密 2024 年报披露，审计委员会成员为刘中华、宋宇红、侯玲玲、张英，共 4 人；报告期内召开会议 4 次 [A1]。年报另披露公司董事会共 7 名董事，其中独立董事 3 名（法律、会计等领域专家），董事会下…	A1

完整 120 字符节选、两位人员分项分值、原始响应文件与 SHA256 及复核说明字段保存在随稿案例清单。此表引文为实际 response.evaluation 的前段，不补写省略的结论；引用 ID 列仅列出实际引用的部分 ID。

7 讨论与有效性限制

7.1 正向效应对应的研究结论

双路检索相对合并检索的正向差异，应与新增来源供给分析一起理解：如果上下文中的公司材料减少，事实性问题就可能缺少公司特有细节；如果法规材料缺失，规范性比较则缺少明确依据。但“哪类片段更多”只是中间机制，仍不能由统计关联直接证明它就是总分变化的因果中介。本文不把候选数量、页位置命中与语义支持率互相替代。

对一个面向实际文件的系统而言，原文可回放和来源组织清晰有独立的工程价值。它们使材料可回放，便于事后复核时定位所用材料，并为区分解析、检索、上下文组装和生成错误提供记录。然而，这种工程价值不能抵消回答质量上的负结果；如果简化配置更好，应保留该现象，而不是只展示符合预期的比较。

7.2 提示约束为何不能预设有益

G3 与 G2 之间没有稳定增量，首先说明在当前上下文和量表条件下，增加来源角色措辞没有显示可辨别的额外收益。G2 的共同提示已经要求引用并限定证据来源，强生成器也可能自行区分事实与规范；这是一种解释，而非已被独立实验验证的原因。另一种可能是评分量表接近天花板，不能分辨细粒度的引用完整性差异。

因此，本文不把零增益改写为“同样证明了角色提示有效”，也不把它解释为在任何任务中都无效。更合适的下一步是预先定义逐论断的必要来源角色、保留未知和冲突类型，在独立问题上测量提示是否改变了具体证据使用，而不是继续用一个接近满分的总分期待更大差距。

7.3 简化基线与组件解释

重排器通常针对相关性训练，但当前任务的回答质量同时取决于公司身份、披露细节、法规主题和材料可用性。高相关性片段不一定包含完整判断所需的互补信息。稠密融合也可能增加语义相近却不支持特定事项的内容。上述机制能够提出错误分析方向，但在没有逐片段语义复核之前，不能直接断言重排器因为某一机制而有害。

人员间对 BM25 比较的方向差异进一步说明，平均结果掩盖了评分尺度与维度的作用。实务选择应同时看效应、费用、失败率和复核难度，而不是默认复杂方案更先进。本研究据此保留 BM25 和去重排作为有竞争力的对照，并将结论限定在所用实现、问题与评分范围。

7.4 专业任务中的不确定性

删除一类来源后的评分下降与材料互补性的解释一致，但该消融同时改变证据内容和上下文长度，不能单独识别来源互补效应。合理的证据不足回答仍可在不确定性维度得分。一个“谨慎而未回答完整”的输出可能保留较高总分。这不一定是量表错误，因为拒绝越界本来就是专业问答的重要行为；但如果目标是同时评价答案完成度，就必须把完成度与保守性拆开。

同样，引用支持维度的高分并不意味着实现了逐规则完整归因。页面上的文字可能只支持一个复合论断的一部分；法规在语义上相关，也可能因生效时间和主体范围而不适用。本文把这些层次明确分开，以避免读者把系统的专业措辞误当作法律判断认证。

7.5 内部有效性

主对照不是在完全未见结果之前设计的确认性实验。原主输出曾被查看，简化评分与均分汇总方案也在不同阶段制定，新增诊断属于事后探索。保留冻结哈希和历史记录能够说明实际执行边界，但不能回溯消除暴露。本文报告点对点区间，不把多个探索性比较当作一组经过家族错误率控制的确认性检验。

失败输出不被记为质量 0 分，因此可用输出上的差异属于条件性结论。最坏有界范围反映未观察质量可能改变方向的程度；逐公司删除检验的是是否被某一个公司簇主导，并不能解决共有法规造成的跨公司相关。两种敏感性针对不同假设，均不替代新增样本。

7.6 外部有效性与资源限制

本轮公司样本和报告年度有限，三个主题也不能代表全部公司自律评价问题。共享法规使公司簇之间可能存在相关，不同年份的披露模板和规范版本变化还可能改变结果。新预算回放使用既有候选，不重新

发现候选池外的证据，因此反映的是保存排序下的组装敏感性，而不是任意预算下重新执行检索的完整系统性能。

补充的法规版本审计发现，本研究问题均以 2024 年报告为背景，而当前知识库中的 DOC100《上市公司信息披露管理办法》、DOC128《上市公司章程指引》和 DOC120《上市公司治理准则》分别对应 2025 年第 226 号令（2025 年 3 月 26 日公布、2025 年 7 月 1 日起施行）、2025 年第 6 号公告（2025 年 3 月 28 日公布并施行）和 2025 年第 18 号公告（2025 年 10 月 16 日公布、2026 年 1 月 1 日起施行）；历史版本方面，第 182 号令、章程指引 2023 年修订后的合并全文及治理准则 2018 年版未独立入库；DOC343 仅为 2023 年修改决定[25–27]。按清单日期检查冻结的法规 top-10 候选，G1 合库检索的 73 条法规候选中有 64 条晚于报告年度，涉及 42/60 题；G2 双路检索的 300 条中有 156 条晚于报告年度，涉及 60/60 题。索引@DATE 口径不一：DOC100 记审议通过日 2025-02-28，DOC128 记公布日 2025-03-28，DOC120 记施行日 2026-01-01[25–27]。故“晚于报告年度”仅是索引时间标记；具体适用仍须结合事项日期及规范的公布、施行、修订和废止状态逐项核实。因此，涉及这些文件的检索与评分只反映当前语料快照，不能解释为 2024 年历史法规版本命中率或时点合规性验证。

此外，截至 2026 年 10 月 27 日，两份法规来源版本复核提交已通过结构校验，但 92 项字段差异仍待仲裁，接受标签为 0；审阅人身份未认证，盲审状态未获验证。这些提交未用于更新知识库版本元数据，也不构成法规时点适用性的独立验证证据。

同系列 K3 与 K2.8 服务别名比较均未发送 reasoning_effort 参数；供应商资料列出的默认值分别为 high 和 max，但响应未记录可独立核实的服务端实际档位，推理预算未统一。底层 checkpoint revision 同样未核验，因此差异不能归因于模型权重，也不能称为跨模型族泛化。每单元一次生成还不足以估计采样波动。本研究不利用这些限制回避负结果，而是用它们约束研究结论，明确哪些观察可以支持，哪些还需新的独立试验。

7.7 结论与部署含义

部署时可优先采用能够保留身份、版本和定位记录的简单配置，明确区分材料缺失、检索未命中与实际不存在。对于涉及法规适用的事项，界面应展示可获得的事项时间与版本依据以及未知状态。这些建议来自本研究观察到的来源供给与法规版本限制；本研究未直接检验其能否降低决策风险、复核成本或人员工作时间。

本文对上市公司年报与法规问答中的双源检索配置进行了受控比较。在 41 个 G1/G2 均有供应商输出的配对问题上，双路检索的公司宏均分高 0.228 分（0–8 分量表，点对点 95%公司聚类区间[0.110, 0.355]）；但保留已观测单侧评分计算的全 60 题均差界为[-1.508, 1.292]，跨越零。因此这只是可用配对上的观察差异，不能断言完整计划题集存在确定优势。相同证据下来源角色提示相对双路检索在 38 个配对问题上的差为+0.013 分（[0.000, 0.039]），未显示稳定增量。来源缺失条件只覆盖 20 题且删除来源同时改变证据内容和上下文长度，不能据其各自可用样本均分推断纯来源效应。来源共现与目标位置覆盖也不等于论断级语义支持。因此，结果限于当前样本、模型和评分协议，不能说明复杂检索配置普遍优于简化基线。

本研究仍受限于 20 家公司、60 个问题、单一报告年度、探索性设计及评分量表天花板。法规知识库未完整提供与 2024 年报告期相匹配的历史版本，因此结果不构成历史法规适用性验证；人工评分也不等同于检索 Precision、Recall 或答案 Accuracy。后续若需提出这些更强主张，应分别建立独立问题集、相关证据标注和盲评协议。

数据与代码可用性

可复现分析脚本、聚合结果、回放明细、图表原始数据及输入哈希清单保存于项目材料。论文公开仓库地址与原文件再分发范围尚未确定，不虚构公开链接。原始文件、评分与运行记录保留，公开时应按其真实授权处理。

参考文献

[1] Lewis P, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems 33 (NeurIPS 2020): 9459–9474. https://proceedings.neurips.cc/paper/2020/hash/6b493230-Abstract.html

[2] Chen Z, et al. FinQA: A Dataset of Numerical Reasoning over Financial Data. EMNLP, 2021: 3697–3711. https://doi.org/10.18653/v1/2021.emnlp-main.300

[3] Zhu F, et al. TAT-QA: A Question Answering Benchmark on a Hybrid of Tabular and Textual Content in Finance. ACL-IJCNLP, 2021: 3277–3287. https://doi.org/10.18653/v1/2021.acl-long.254

[4] Choe J, Kim J, Jung W. Hierarchical Retrieval with Evidence Curation for Open-Domain Financial Question Answering on Standardized Documents. Findings of ACL, 2025: 16663–16681. https://doi.org/10.18653/v1/2025.findings-acl.855

[5] Siddharth L, Luo J. Retrieval augmented generation using engineering design knowledge. Knowledge-Based Systems 303, 2024: 112410. https://doi.org/10.1016/j.knosys.2024.112410

[6] Yang W, Some L, Bain M, Kang B. A comprehensive survey on integrating large language models with knowledge-based methods. Knowledge-Based Systems 318, 2025: 113503. https://doi.org/10.1016/j.knosys.2025.113503

[7] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval 3(4), 2009: 333–389. https://doi.org/10.1561/1500000019

[8] Karpukhin V, et al. Dense Passage Retrieval for Open-Domain Question Answering. EMNLP, 2020: 6769–6781. https://doi.org/10.18653/v1/2020.emnlp-main.550

[9] Zhang Y, et al. Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models. arXiv, 2025. https://arxiv.org/abs/2506.05176

[10] Cormack G V, Clarke C L A, Buettcher S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. SIGIR, 2009: 758–759. https://doi.org/10.1145/1571941.1572114

[11] Alier M, García-Peñalvo F J, Casañ M J, Pereira J, Granados A. Closing the acronym gap in educational retrieval with ontology-guided augmentation. Information Sciences 740, 2026: 123181. https://doi.org/10.1016/j.ins.2026.123181

[12] Asai A, Wu Z, Wang Y, Sil A, Hajishirzi H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection. ICLR, 2024. https://arxiv.org/abs/2310.11511

[13] Yan S Q, Gu J C, Zhu Y, Ling Z H. Corrective Retrieval Augmented Generation. arXiv, 2024. https://arxiv.org/abs/2401.15884

[14] Jeong S, Baek J, Cho S, Hwang S J, Park J. Adaptive-RAG: Learning to Adapt Retrieval-Augmented Large Language Models through Question Complexity. NAACL, 2024: 7036–7050. https://doi.org/10.18653/v1/2024.naacl-long.389

[15] Han W, Xiao X, Li Y, Wang J, Pechenizkiy M, Fang M. Adaptive iterative retrieval for enhanced retrieval-augmented generation. Neurocomputing 666, 2026: 132272. https://doi.org/10.1016/j.neucom.2025.132272

[16] Yao S, et al. ReAct: Synergizing Reasoning and Acting in Language Models. International Conference on Learning Representations (ICLR 2023). https://arxiv.org/abs/2210.03629

[17] Li B, Fan S, Zhu S, Wen L. CoLE: A collaborative legal expert prompting framework for large language models in law. Knowledge-Based Systems 311, 2025: 113052. https://doi.org/10.1016/j.knosys.2025.113052

[18] Wang H, et al. Learning to break: Knowledge-enhanced reasoning in multi-agent debate system. Neurocomputing 618, 2025: 129063. https://doi.org/10.1016/j.neucom.2024.129063

[19] Gao T, Yen H, Yu J, Chen D. Enabling Large Language Models to Generate Text with Citations. EMNLP, 2023: 6465–6488. https://doi.org/10.18653/v1/2023.emnlp-main.398

[20] Es S, James J, Espinosa Anke L, Schockaert S. RAGAs: Automated Evaluation of Retrieval Augmented Generation. EACL System Demonstrations, 2024: 150–158. https://doi.org/10.18653/v1/2024.eacl-demo.16

[21] Ru D, et al. RAGChecker: A Fine-grained Framework for Diagnosing Retrieval-Augmented Generation. Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track. https://doi.org/10.52202/079017-0692

[22] Pipitone N, Alami G H. LegalBench-RAG: A Benchmark for Retrieval-Augmented Generation in the Legal Domain. arXiv, 2024. https://arxiv.org/abs/2408.10343

[23] Liu N F, et al. Lost in the Middle: How Language Models Use Long Contexts. TACL 12, 2024: 157–173. https://doi.org/10.1162/tacl_a_00638
[24] Kimi. 模型配置. 服务别名与默认思考档位说明；底层 checkpoint revision 及运行时档位未核实，核对日期 2026-10-20 及 2026-10-23。 https://www.kimi.com/help/kimi-code/models
[25] 中国证监会. 第 182 号令《上市公司信息披露管理办法》（2021）及第 226 号令《上市公司信息披露管理办法》（2025）。
https://www.csrc.gov.cn/csrc/c101864/c2ee1a791fddc4f5ebeeb70aa8e2399cf/content.shtml;
https://www.csrc.gov.cn/csrc/c101953/c7547359/content.shtml
[26] 中国证监会. 第 62 号公告《关于修改〈上市公司章程指引〉的决定》（2023）及第 6 号公告《上市公司章程指引》（2025）。 https://www.csrc.gov.cn/csrc/c101954/c7449659/content.shtml;
https://www.csrc.gov.cn/csrc/c101954/c7547791/content.shtml
[27] 中国证监会. 第 29 号公告《上市公司治理准则》（2018）及第 18 号公告《上市公司治理准则》（2025）。 https://www.csrc.gov.cn/csrc/c101864/c1024585/content.shtml;
https://www.csrc.gov.cn/csrc/c101954/c7589726/content.shtml
[28] Wang R, Balloccu S. ARQA: A Benchmark for Grounded Table–Text QA in Enterprise Annual Reports. Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics, Industry Track, 2026: 847–868. https://doi.org/10.18653/v1/2026.eacl-industry.63
[29] Zhu T, Liu M, Kurfali M. CFQA: A Chinese Financial Question Answering Benchmark from Corporate Annual Reports. Proceedings of the 7th Financial Narrative Processing Workshop, 2026: 28–38. https://doi.org/10.63317/4e6fhrncfrbu

附录 A 回放与审计复现说明

分析续接冻结记录为 results/runs/paper_execution_freeze_windows_20261020_01/execution_freeze.json，SHA256 为 f0eecd3e4f7f129364311b2daa86d0e2ca6aad6af57ac269a14c210be3ffc2c7；它固定既有参考、公司分组和主设置，并封存后续恢复/扩展决策，不是追溯性预注册。原始执行计划另见 results/runs/compact_final_execution_windows_20261020_01/execution_plan.json；两份记录指向相同的参考清单 SHA256 9f9c0f73fb0ae308394399dfd57f25d2deaca6ae5ad141b6acb5d425a9d91fc3。原始主结果不因本次新增分析覆盖。新增回放、稀疏检索与评分诊断分别保存在本稿目录下 retrieval、quality 和 audit 中，运行脚本及输入哈希列入交付清单.

执行核验包括 400 个计划单元、355 条纳入分析的供应商输出、386 条历史评分记录及其 3,088 个原始评分字段；其中 31 条会话补充回答已从重分析中排除。原配置 120 个上下文逐字一致，参考证据 123 条参考来源位置均可在索引中定位。评分者在正文仅以人员 1、人员 2 表示；历史评分和失败记录保留，新增分析不回溯称为预注册。

附录 B 写作与投稿状态

本稿为中文实证研究稿，含英文题名与摘要，当前版本聚焦年报与法规双源 RAG 的检索组织比较。作者、单位、基金、利益冲突、CRediT 和 AI 辅助写作披露须由作者按真实情况补齐。版式参考已取得全文的领域 RAG 实证论文，采用单栏与可编辑表格；不复制出版社刊头或出版身份。作者信息核对并选定目标期刊后，仍需按其模板整理。篇幅和图表数量不构成期刊分区或录用保证。跨年度与 Agent 扩展材料保留在原合并扩展稿中，不计入本聚焦稿的主结果。